



데이터 생성모델을 활용한 군용기 분류 학습 데이터 증강기법

DATA AUGMENTATION VIA GENERATION MODEL IN MILITARY AIRCRAFT CLASSIFICATION

전인수 · 윤준혁 · 홍민익 · 김건희
Vision and Learning Lab, Seoul National University, Seoul, Korea



SEOUL NATIONAL UNIV.
VISION & LEARNING


연구배경

- 민간 데이터에 비해 군용 데이터는 희소하고, 아군과 적군 데이터 간의 불균형이 존재한다. 이는 군용 지능형 시스템에 활용될 딥러닝 모델의 성능 향상에 병목 현상을 초래한다.
- 최근 데이터 증강 기법을 활용하여 데이터 부족 및 불균형을 완화하는 접근법이 연구되고 있다.
- 본 연구는 군용 데이터 부족 및 불균형 문제를 해결하기 위해 데이터 증강 기법과 데이터 생성 모델을 함께 활용한 방법을 제안한다.
- 아군 군용기에 비해 적군 군용기 데이터가 적은 적군 및 아군 군용기 탐지 시나리오를 가정하여 국방 벤치마크 DB를 구축하고, 군용기 데이터 생성 모델을 활용하여 해당 DB의 데이터 부족 및 불균형 현상을 완화한다.
- 제안한 데이터 생성 모델을 사용하기 전과 후의 군용기 class 분류기 모델의 성능을 비교하여 해당 방법론의 실효성 및 발전 가능성을 검증한다.

벤치마크 데이터 수집

- 서로 다른 76개의 군용기 class에 대해서 총 16400개의 군용기 데이터를 포함하는 국방 벤치마크 DB를 구축하였다.
- 군용 데이터는 희소하여 수집하기에 한계가 있었으며, 임의로 가공하지 않아도 군용기 class 간 불균형이 존재했으며, 군용 데이터의 불균형은 자연적으로 발생함을 확인하였다.

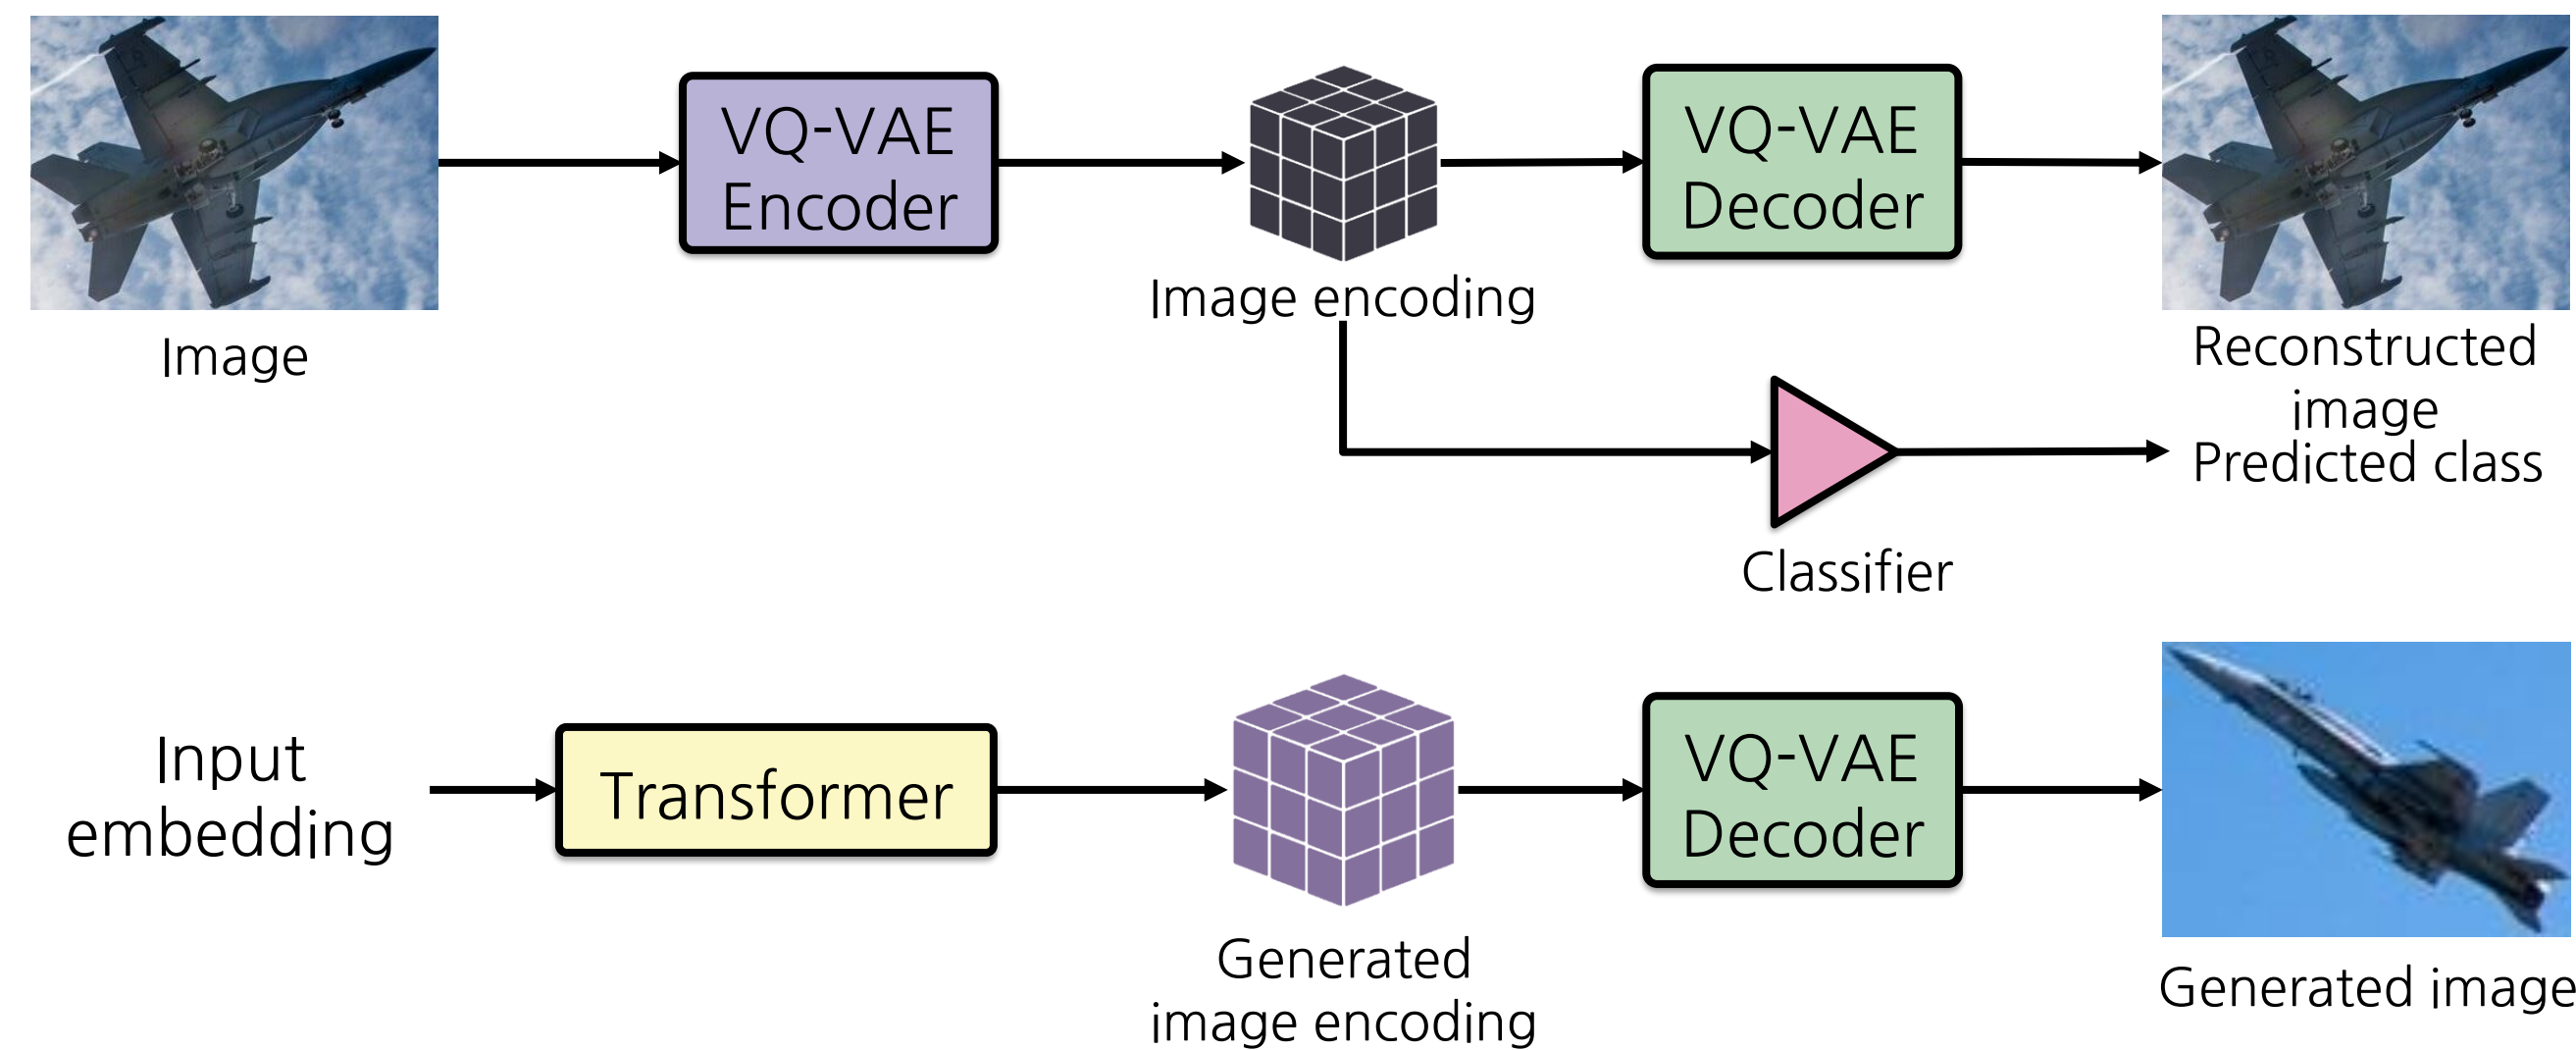
Figure1. 군용기 class별 데이터 수



데이터 생성 모델 학습

- 군용기 데이터 생성 모델로서 텍스트 캡션을 입력받아 이미지를 생성하는 기존 DALL-E 모델의 구조를 본 연구의 목적에 맞게 수정한 Modified DALL-E 모델을 새로 정의하였다.
- DALL-E 모델은 VQ-VAE와 Transformer로 구성된다. VQ-VAE는 이미지를 입력받아 해당 이미지의 encoding을 출력하는 Encoder와 encoding을 입력받아 이미지를 복원하는 Decoder로 구성된다. Transformer는 Input embedding을 입력받아 VQ-VAE Decoder의 입력으로 사용되는 encoding을 출력한다.
- 본 연구에서는 각 군용기 class 간의 차이점을 강조하기 위해서 VQ-VAE 구조에 분류기를 추가하였다. 이 분류기가 VQ-VAE에 입력되는 군용기 이미지의 class를 잘 분류하는 방향으로 학습함으로써 VQ-VAE가 각 군용기 class의 특징, 즉 class conditional한 정보를 잘 학습하도록 하였다.
- 학습은 두 단계로 이루어진다. Modified VQ-VAE가 입력받은 이미지를 잘 복원하고 해당 이미지의 class를 잘 분류하도록 학습한 후, 학습된 Modified VQ-VAE의 Decoder를 활용해서 Modified DALL-E가 입력받은 군용기 class의 특징을 포함하는 군용기 이미지를 생성하도록 학습한다.

Figure2. Modified DALL-E 구조



성능 검증

군용기 데이터 생성 모델 성능 검증


- 학습된 Modified DALL-E 모델은 군용기 class 정보를 포함한 Input embedding을 입력으로 받아서 해당 군용기 class에 해당하는 이미지를 출력한다.
- 그 결과 Figure3.과 같이 각 class별로 서로 다른 특징을 가지는 High fidelity 군용기 이미지들을 생성하였다.

Figure3. Modified DALL-E로 class conditional하게 생성된 군용기 이미지 예시



이미지 생성 기반 데이터 증강 기법 성능 검증

Figure4. Modified DALL-E로 생성된 데이터를 활용해 증강한 벤치마크 DB의 데이터 수



- 군용기 데이터 생성 모델로 생성한 군용기 데이터 추가 활용하였을 때 ResNet-152 모델의 분류 정확도가 향상되는지 검증하였다.
- 1차 실험: 국방 벤치마크 DB의 학습 데이터만으로 군용기 분류기를 학습시킨 후, 테스트 데이터에 대한 분류 정확도를 측정하였다.
- 2차 실험: 이미지 합성 기반 데이터 증강 기법을 활용하여 학습 데이터를 증강한 후 분류기를 학습하여 분류 정확도를 측정하였다.
- 3차 실험: 데이터가 적은 하위 35개의 군용기 class들에 대해서 군용기 데이터 생성 모델로 생성한 데이터를 100개씩 추가하여 Figure4 와 같이 학습 데이터의 불균형을 완화하였다. 이후 이미지 합성 기반 데이터 증강 기법을 활용하여 학습 데이터를 더욱 증강한 후 분류기를 학습하여 분류 정확도를 측정하였다.
- 각 실험에서 사용된 학습 데이터만 다를 뿐, 분류기 학습을 위한 하이퍼파라미터와 테스트 데이터는 동일하게 설정하였다.

Table1. 군용기 class 분류기의 분류 정확도 비교

| 학습 데이터에 따른 실험 | 분류 정확도 |
|--|--------|
| 1차 실험 (데이터 증강을 활용하지 않음) | 68.8 % |
| 2차 실험 (이미지 합성 기반 데이터 증강) | 69.7 % |
| 3차 실험 (생성 모델 기반 데이터 증강 + 이미지 합성 기반 데이터 증강) | 75.1 % |

결론

연구 요약 및 활용 가능성

- 본 연구에서는 군용 데이터 부족 및 불균형 문제를 해결하기 위해, 데이터 생성 모델인 Modified DALL-E를 제안하였다.
- 군용기 감지 시나리오를 가정하여 국방 벤치마크 DB를 구축하였고, Modified DALL-E를 통해 생성된 군용 데이터를 학습시킴으로써 분류 모델의 성능 향상을 확인하였다.
- 실험에서는 Modified DALL-E를 군용기 이미지 생성에 사용하였지만, 시나리오에 따른 다양한 군용 데이터를 학습 및 생성하여 데이터 불균형 문제를 해결할 수 있다.
- 데이터 생성 모델은 분류 뿐만 아니라 객체 탐지 등의 다양한 국방 관련 인공지능 다운스트림 태스크에서 데이터 생성 기반 데이터 증강 기법으로 활용될 수 있다.
- 제안한 Modified DALL-E는 기존 DALL-E 모델을 군용 이미지 생성에 특화시킨 것으로, 이는 향후 Multi-Modal 생성 모델의 개발에 중요한 기반이 될 것이다.
- 본 연구는 데이터 생성 모델을 통해 군용 데이터의 희소성과 불균형 문제를 해결하며, 군용 지능형 시스템의 성능 향상을 가능케 함을 확인하였다. 이러한 접근 방식은 민간 및 상업용 데이터에도 적용 가능하며, 딥러닝 모델의 성능 향상에 크게 기여할 것으로 예상된다.